

---

# Neural SDE: phase trajectories of SDE in the action

---

A Preprint

Papay Ivan  
MIPT University  
papai.id@phystech.edu

Vladimirov Eduard  
MIPT University

2024 год

Данная статья предлагает углубиться в математический аппарат, на котором строится модель Neural SDE. В ней будет рассмотрено, как вычисление фазовых траекторий СДУ обеспечивает качественный прогноз аномалий во временном ряду. Таким образом это предоставит как возможность эффективнее бороться с шумами, так и, в частности, полезный инструмент для упреждения "чёрных лебедей" которые могли бы нарушить корректную работу Neural SDE в виду высокой корреляции элементов анализируемой выборки между собой.

Keywords SDE · Stratonovich integral · More

## 1 Введение

Сбор данных и подготовка их к последующей обработке всегда были одной из важнейших задач машинного обучения. К сожалению не всегда исследователь может гарантировать их целостность и корректность, ведь для тренировки модели чаще всего требуются выборки из тысяч, а то и десятков тысяч элементов - не удивительно, что в данных допускается наличие "шума влияющего на работу обученной модели. Эта задача остаётся актуальной и для временных рядов, то есть данных, индексированных относительно временной координаты. Естественно желание - имея данные для начала временного ряда, проверить: возможно ли продолжить его новыми данными, насколько такое продолжение будет естественно, и не сломает ли это природу текущего временного ряда в стохастическом смысле?

Отсюда и далее мы сконцентрируемся на работе исключительно с временными рядами. В таком наши данные будут представлять из себя данные о некоем дискретном случайном процессе. Дискретном, потому как входная выборка, как множество, точно не будет континуально в силу естественной ограниченности анализируемых данных. Тем не менее корректно будет перейти к непрерывному случайному процессу в силу того факта, что он порождается сигма-алгеброй из конечномерных распределений, которые реально аппроксимировать с помощью данных, предоставленных для обучения модели.

Но пока что это всего лишь слова - как именно мы будем аппроксимировать искомые распределения? Если бы природа данных была бы строго детерминированной и мы бы изначально имели представление о распределении рассматриваемого случайного процесса, уместно было бы применить метод интерполяции или линейной регрессии. Но в условиях полной неопределённости по отношению и к характеру распределений, как функций, и к её параметрам - нам потребуется что-то другое. Как вариант: аппроксимировать ряд дифференциальными уравнениями.

Сама идея использования обыкновенных дифференциальных уравнений ("ОДУ"отсюда и далее) далеко не так нова[1], как могло бы показаться на первый взгляд. Так, примерно с 2017-го года она была использована[2] для создания и теоретического обоснования корректности работы модели Neural ODE. Тем не менее, такой метод был всё ещё слаб в робастном смысле: то есть модель легко подпадала под влияние гауссовского шума, а также была уязвима к состязательным атакам. Модель Neural SDE уже строилась на использовании стохастических дифференциальных уравнений ("СДУ"отсюда и далее) и была в этом плане эффективнее своего предшественника. Математический аппарат требовался ещё

более серьезный, ведь для вычисления решения СДУ без знаний стохастического анализа, исчисления Ито и Стратоновича обойтись было нельзя.

Главной целью данного исследования является построение decision-rejection(принятие-отрицание) критерия корректности той или иной гипотезы о вероятностном распределении входных данных, как некоторого непрерывного случайного процесса. Таким образом для проверки фрагмента временного ряда на наличие аномалий достаточно применить этот критерий для проверки гипотезы о тождественности распределений для конкретного диапазона и для всего остального ряда - разумно будет заключить, что в ряду происходят аномалии, если природа данных в стохастическом смысле резко поменялась.

Вопрос состоит в том: как мы собираемся это делать? Ответ следующий - полагая, что временной ряд порождается определенными конечномерными распределениями, мы сможем приблизить его с помощью стохастических дифференциальных уравнений. То же, разумеется, применимо и к анализируемому диапазону, который требуется проверить на наличие аномалий. Если фазовые траектории полученных дифференциальных уравнений различаются, то есть происходит резкое их возмущение, то очевидно, что в ряду произошла аномалия.

В прошлых работах, связанных с Neural SDE[2,3,4], СДУ использовались только для построения доверительных интервалов для элементов временного ряда. Этот подход в статье предлагается развить посредством использования фазовых траекторий полученных СДУ. Таким образом, можно будет проверять большие массивы данных на корреляцию между собой. В том числе рассматривается конкретная задача - проверить, что два временных ряда обладают одинаковым вероятностным распределением. А именно проверяется соответствие видеоряда готовки еды и ряда данных, полученных с акселерометра, прикрепленного к его руке: ускорения по трём осям x,y,z. Обладают ли эти данные одной и той же природой?

## 2 Фазовые траектории и Neural SDE

Давайте подытожим: перед нами стоят следующие задачи - применить метод Neural ODE к временному ряду, учесть гауссовский шум и тем самым свести задачу к модели Neural SDE, вычислить фазовые траектории для временных рядов, предварительно свернув два многомерных временных ряда(из видео и из акселерометра) к минимально возможному размеру и, наконец, сравнить полученные фазовые траектории временных рядов по поведению.

### 2.1 Neural ODE

Изначально Neural ODE был разработан как альтернатива методу остаточных нейронных сетей, состоящих из последовательности скрытых слоёв, значения на каждом из которых подчинялись следующей формуле:

$$h_{n+1} = h_n + f(h_n, w_n), \quad (1)$$

Где  $h_n$  - вход n-го слоя и  $f(h_n, w_n)$  - нелинейная функция, параметризованная по  $w_n$

Было предложено[5] представление (1) в виде:

$$h_t = h_s + \int_s^t f(h_l, l; w) dl, \quad (2)$$

А вычисление такого дифференциального уравнения уже есть задача для Neural ODE

---

#### Algorithm 1 Neural ODE-solver

---

Require: динамические параметры  $w$ , начальное/конечное время  $t_0, t_1$ , конечное значение  $z(t_1)$ , градиент функции потерь в конечной точке  $\frac{\delta L}{\delta z(t_1)}$

$s_0 = [z(t_1), \frac{\delta L}{\delta z(t_1)}, 0_{[w]}]$  ▷ Начальное состояние

$[z(t_0), \frac{\delta L}{\delta z(t_1)}, \frac{\delta L}{w}] = \text{ODESolve}(s_0, [f(z(t), t, w), -a(t)^T \frac{\delta f}{\delta z}, -a(t)^T \frac{\delta f}{\delta w}], t_1, t_0, w)$

return  $\frac{\delta L}{\delta z(t_0)}, \frac{\delta L}{w}$  ▷ Возвращаем градиенты

---

## 2.2 Neural SDE

Для учёта шума в наше дифференциальное уравнение следует добавить недетерминированную компоненту, случайную величину. Получится следующее выражение, являющееся интегралом Стратоновича:

$$dX_t^w = h(t, X_t^w; w)dt + \sigma(X_t^w; w)dB_t, \quad (3)$$

Где  $B_t = [B_t^1 \dots B_t^n]$  -  $n$ -мерный Винеровский процесс

## 2.3 Построение фазовых траекторий по SDE

### 2.3.1 Ганкелевы матрицы и ODE

В данном случае в силу детерминированности компонент диффура достаточно было бы взять  $w$ , который, как мы показали легко считается с помощью соответствующего солвера.

### 2.3.2 Обработка диффузии для SDE

Как ранее было показано, SDE по сути, так же, как и интеграл Стратоновича, обычная случайная величина. Занулив диффузию и отсеплировав выборку мы тем самым получим траектории характерные для стохастической части диффура. Правда они будут не так сильно выражены чем траектории от детерминированной части. Уместно будет к Ганкелевой матрице из предыдущего пункта прибавить ганкелевы матрицы из этого, домноженные на предельно малый коэффициент.

## 2.4 Свёртка многомерных временных рядов

Следует использовать Convergent-Cross Mapping (CCM) для того, чтобы привести два анализируемых временных ряда к одному и тому же размеру.

## 2.5 Компарация фазовых траекторий двух временных рядов

Для сравнения двух фазовых траекторий, как матриц, просто применим метод PCA для выделения главных компонент - и найдем норму Фробениуса разницы этих двух матриц. Если эта разница будет крайне мала, то очевидна схожесть природы двух процессов: иначе - гипотеза под вопросом.

## Список литературы

- [1] “Neural Ordinary Differential Equations Ricky” T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, David Duvenaud
- [2] “Neural SDE: Stabilizing Neural ODE Networks with Stochastic Noise” Xuanqing Liu, Tesi Xiao, Si Si, Qin Cao, Sanjiv Kumar, Cho-Jui Hsieh
- [3] “Riemannian Neural SDE: Learning Stochastic Representations on Manifolds” Sung Woo Park , Hyomin Kim , Kyungjae Lee , Junseok Kwon
- [4] “Riemannian Diffusion Models” Chin-Wei Huang, Milad Aghajohari, Avishek Joey Bose, Prakash Panangaden, Aaron Courville
- [5] Tian Qi Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In Advances in Neural Information Processing Systems, pages 6572–6583, 2018.