

# Neural SDE для нахождения моментов разладки временных рядов

Папай Иван Дмитриевич

Московский физико-технический институт

*Курс:* Автоматизация научных исследований  
(практика, В. В. Стрижов)/Группа 1286

*Эксперт:* к.ф. м.н.,с. ВЦ РАН В. В. Стрижов

*Консультант:* студент магистратуры 5 курс Э. А. Владимиров

2024

# Цель исследования

## Цель

Главной целью исследования является подбор оптимального способа поиска точек разладки во временных рядах. Под точками разладки понимаются позиции временного ряда, по достижению которых временной ряд резко меняет свое поведение в своем стохастическом смысле.

## Задача

По имеющемуся временному ряду уметь вычислять его точки разладки. При этом ошибка первого рода у модели должна быть минимальной.

# Суть вкратце




Рис.: локальная разладка




Рис.: глобальная разладка

- [1] “Neural Ordinary Differential Equations Ricky” T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, David Duvenaud
- [2] “Neural SDE: Stabilizing Neural ODE Networks with Stochastic Noise” Xuanqing Liu, Tesi Xiao, Si Si, Qin Cao, Sanjiv Kumar, Cho-Jui Hsieh
- [3] “Riemannian Neural SDE: Learning Stochastic Representations on Manifolds” Sung Woo Park , Hyomin Kim , Kyungjae Lee , Junseok Kwon
- [4] “Riemannian Diffusion Models” Chin-Wei Huang, Milad Aghajohari, Avishek Joey Bose, Prakash Panangaden, Aaron Courville
- [5] Tian Qi Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. In Advances in Neural Information Processing Systems, pages 6572–6583, 2018.

# Модель ResNet

Изначально Neural ODE был разработан как альтернатива методу Residual Networks(ResNet), состоящих из последовательности скрытых слоёв, значения на каждом из которых подчинялись следующей формуле:

$$h_{k+1} = h_k + f(h_k, w_k) \quad (1)$$

— где  $h_k$  - вход  $k$ -го слоя для  $k \in [1, K]$ ,  $K$ -число слоёв и  $f(h_k, w_k)$  - функция, параметризованная по  $w_k$  - динамический параметр, задающийся перед началом обучения модели.

## Residual net




Рис.: схематичное описание работы

# Модель Neural ODE

$$h_t = h_s + \int_s^t f(h_l, l; w) dl, \quad (2)$$

— вычисление такого дифференциального уравнения является задачей для Neural ODE. В данной работе в качестве числа слоев берется число элементов во временном ряду.

---

## Algorithm 1 Neural ODE-solver

---

Require: динамические параметры  $w$ , начальное/конечное время  $t_0, t_1$ , конечное значение  $z(t_1)$ , градиент функции потерь в конечной точке  $\frac{\delta L}{\delta z(t_1)}$

$s_0 = [z(t_1), \frac{\delta L}{\delta z(t_1)}, 0_{[w]}]$  ▷ Начальное состояние

$[z(t_0), \frac{\delta L}{\delta z(t_1)}, \frac{\delta L}{w}] = \text{ODESolve}(s_0, [f(z(t), t, w), -a(t)^T \frac{\delta f}{\delta z}, -a(t)^T \frac{\delta f}{\delta w}], t_1, t_0, w)$

$\text{return } \frac{\delta L}{\delta z(t_0)}, \frac{\delta L}{w}$  ▷ Возвращаем градиенты

---

Рис.: псевдокод Neural ODE

Здесь ODEsolve - это черный ящик, возвращающий решение ODE — в качестве него предлагается использовать метод Рунге-Кутты, а L — MSE (mean squared error — среднее квадратов отклонения элементов выборки от их оценок).

В случае анализа временных рядов было предложено [7] рассматривать не классический интеграл Римана-Стилтьеса, а стохастический интеграл Стратоновича:

$$h_t = h_s + \int_s^t f(h_l, l; w) dB_l, \quad (3)$$

— где  $B_t = [B_t^1 \dots B_t^K]$  - Винеровский процесс той же размерности, что и  $X_t$ .

Таким образом получается контролируемое дифференциальное уравнение, подходящее для данных типа Time-Series, особенно когда временные метки ряда не являются регулярными в плане тождественности их расстояний между собой.

## Модель Neural SDE

Обобщением предыдущих двух методов является модель Neural SDE. Для учёта шума и максимально возможной аппроксимации прогноза в нашем дифференциальное уравнение следует учесть и недетерменированную компоненту, и диффузию. Получится следующее выражение, являющееся полным стохастическим дифференциалом:

$$dX_t^w = h(t, X_t^w; w)dt + \sigma(X_t^w; w)dB_t \quad (4)$$

— где  $B_t = [B_t^1 \dots B_t^K]$  - Винеровский процесс той же размерности, что и  $X_t$ , а  $\sigma(X_t^w; w)$  - его матрица ковариаций в  $t$ -й момент времени

Обобщим это выражение для модели ResNet:

$$dh_t = f(h_t, t, w), \quad (5)$$

— таким образом выражение (1) для  $(k+1)$ -го слоя изменится:

$$h_{k+1} = h_k + f(h_k, w_k) + \sigma(X_k^w; w)B_k, \quad (6)$$

— соответственно алгоритм остаётся тем же, что и для ODE.



# Вычислительный эксперимент(пример выборки)




Рис.: выборка




Рис.: происхождение разных отрезков ряда

# Вычислительный эксперимент(подбор параметров)




Рис.: подбор ширины окна

# Вычислительный эксперимент(процесс обучения)




Рис.: процесс обучения

Строится матрица Ганкеля, описывающая фазовые траектории процесса, размера  $(n+1)$  на  $w$  вида:

$$\begin{bmatrix} f_1 & f_2 & \cdots & f_w \\ f_2 & f_3 & \cdots & f_{w+1} \\ \vdots & \vdots & \ddots & \vdots \\ f_{n+1} & f_{n+2} & \cdots & f_{n+w} \end{bmatrix} \quad (7)$$

— где  $n$  - размер выборки,  $w$  - ширина окна.

# Результаты поиска точек разладки




Рис.: воссоздание их фаз.траекторий с помощью Neural SDE

## Сравнение с другими моделями

<i>Model</i>	<i>Speed(sec)</i>	<i>Error</i>
<i>NeuralODE</i>	34.7	0.054
<i>NeuralCDE</i>	32.5	0.0545
<i>NeuralSDE</i>	47.2	0.044
<i>SSA</i>	6.48	0.12
<i>CuSum</i>	3.56	0.08
<i>CuSumSqr</i>	20.03	0.061

(8)

- ▶ Результатом проведенной работы является обоснование корректности нового способа поиска точек разладки на практике. Плюсы и минусы метода ясны, и зная их, исследователь способен использовать его как новый и полезный инструмент.
- ▶ Дальнейшим направлением исследования будет оптимизация работы алгоритма и поиск способов уменьшить время, необходимое для его исполнения.